

Министерство науки и высшего образования Российской Федерации
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
“НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ ИТМО”

Факультет	Программной Инженерии и Компьютерной Техники
Направление подготовки (специальность)	
Дисциплина	Интеллектуальная обработка экспериментальных данных

ЛАБОРАТОРНАЯ РАБОТА 1
ОТЧЕТ

Выполнил студент: *Касьяненко Вера Михайловна (368283)*

Группа:

Преподаватель: *Болдырева Елена Александровна (157150)*

г. Санкт-Петербург

2025

Содержание	
ЦЕЛЬ АНАЛИЗА	2
ПРЕДВАРИТЕЛЬНЫЙ ОБЗОР ДАННЫХ	2
ПРЕДОБРАБОТКА ДАННЫХ	4
ЗАКЛЮЧЕНИЕ	9

ЦЕЛЬ АНАЛИЗА

Цель исследования – оценить влияние различных факторов на эффективность работы сотрудников компании.

Для достижения цели необходимо провести анализ статистических данных о сотрудниках компании, включая возраст, образование, стаж, показатели KPI, участие в обучении и награды. Результаты исследования могут быть использованы для построения аналитических моделей, например, модели прогнозирования повышения, которая позволит отделу HR принимать более обоснованные решения о развитии и продвижении персонала.

ПРЕДВАРИТЕЛЬНЫЙ ОБЗОР ДАННЫХ

В качестве объекта исследования выбран датасет «HR Analysis Case Study», содержащий сведения о возрасте, образовании, стаже, выполнении KPI, наградах, участии в тренингах, рейтинге за предыдущий год и других характеристиках, собранный дата-сайентистом из Индии.

Для начала загрузим датасет в Google Colab:

```
# Загрузка данных
df = pd.read_csv("data.csv")
```

Посмотрим, сколько строк и столбцов содержит таблица:

```
# Проверяем размерность датасета (строки, столбцы)
df.shape

(23490, 13)
```

Результат показывает количество записей и признаков. В нашем случае 15762 строки и 13 столбцов.

Просмотрим содержимое первых 10 строк:

```
# Просматриваем первые 10 строк, чтобы понять структуру данных
df.head(10)
```

	employee_id	department	region	education	gender	recruitment_channel	no_of_trainings	age	previous_year_rating	length_of_service	KPIs_met >80%	awards_won?	avg_training_score
0	8724	Technology	region_26	Bachelor's	m	sourcing	1	24	NaN	1	1	0	77
1	74430	HR	region_4	Bachelor's	f	other	1	31	3.0	5	0	0	51
2	72255	Sales & Marketing	region_13	Bachelor's	m	other	1	31	1.0	4	0	0	47
3	38562	Procurement	region_2	Bachelor's	f	other	3	31	2.0	9	0	0	65
4	64486	Finance	region_29	Bachelor's	m	sourcing	1	30	4.0	7	0	0	61
5	46232	Procurement	region_7	Bachelor's	m	sourcing	1	36	3.0	2	0	0	68
6	54542	Finance	region_2	Bachelor's	m	other	1	33	5.0	3	1	0	57
7	67269	Analytics	region_22	Bachelor's	m	sourcing	2	36	3.0	3	0	0	85
8	66174	Technology	region_7	Master's & above	m	other	1	51	4.0	11	0	0	75
9	76303	Technology	region_22	Bachelor's	m	sourcing	1	29	5.0	2	1	0	76

Проверим типы данных и наличие пропусков:

```
# Проверка типов данных, количество непустых значений
df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 23490 entries, 0 to 23489
Data columns (total 13 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   employee_id                          23490 non-null  int64
1   department                           23490 non-null  object
2   region                               23490 non-null  object
3   education                            22456 non-null  object
4   gender                               23490 non-null  object
5   recruitment_channel                  23490 non-null  object
6   no_of_trainings                      23490 non-null  int64
7   age                                  23490 non-null  int64
8   previous_year_rating                 21678 non-null  float64
9   length_of_service                    23490 non-null  int64
10  KPIs_met >80%                       23490 non-null  int64
11  awards_won?                         23490 non-null  int64
12  avg_training_score                   23490 non-null  int64
dtypes: float64(1), int64(7), object(5)
memory usage: 2.3+ MB
```

Здесь видно, что часть столбцов имеет тип object, а числовые признаки представлены в int64 и float64. Некоторые признаки содержат пропуски (education, previous_year_rating).

Проверим базовые статистические характеристики (среднее, минимум, максимум, стандартное отклонение):

```
# Проверка базовых статистических характеристик
df.describe()
```

	employee_id	no_of_trainings	age	previous_year_rating	length_of_service	KPIs_met >80%	awards_won?	avg_training_score
count	23490.000000	23490.000000	23490.000000	21678.000000	23490.000000	23490.000000	23490.000000	23490.000000
mean	39041.399149	1.254236	34.782929	3.339146	5.810387	0.358834	0.022776	63.263133
std	22640.809201	0.600910	7.679492	1.263294	4.207917	0.479668	0.149191	13.411750
min	3.000000	1.000000	20.000000	1.000000	1.000000	0.000000	0.000000	39.000000
25%	19370.250000	1.000000	29.000000	3.000000	3.000000	0.000000	0.000000	51.000000
50%	38963.500000	1.000000	33.000000	3.000000	5.000000	0.000000	0.000000	60.000000
75%	58690.000000	1.000000	39.000000	4.000000	7.000000	1.000000	0.000000	76.000000
max	78295.000000	9.000000	60.000000	5.000000	34.000000	1.000000	1.000000	99.000000

ПРЕДОБРАБОТКА ДАННЫХ

Приведем имена столбцов к единому формату (snake_case) и уберем спецсимволы (?, %, >). Это улучшит читаемость и может предотвратить ошибки при обращении к столбцам.

```
# Приводим имена к единому стилю, убираем спецсимволы
df.rename(columns={
    'no_of_trainings': 'trainings_count',
    'length_of_service': 'service_years',
    'KPIs_met >80%': 'kpi_met_80',
    'awards_won?': 'awards_won'
}, inplace=True)
```

Преобразуем категориальные признаки. Пол приведен к полным английским словам для удобства. Значения образования унифицированы и переведены в нижний регистр.

```
# Приводим обозначения пола к понятному виду
df['gender'] = df['gender'].replace({'m': 'male', 'f': 'female'})
```

```
# Приводим уровни образования к нижнему регистру и стандартным названиям
df['education'] = df['education'].str.lower().replace({
    "bachelor's": 'bachelor',
    "master's & above": 'master',
    "secondary": 'secondary'
})
```

Проверим количество пропусков:

```
# Проверка количества пропусков в каждом столбце
df.isna().sum()
```

	0
employee_id	0
department	0
region	0
education	1034
gender	0
recruitment_channel	0
trainings_count	0
age	0
previous_year_rating	1812
service_years	0
kpi_met_80	0
awards_won	0
avg_training_score	0

dtype: int64

Пропуски обнаружены в двух признаках: education и previous_year_rating.

Заменим пропуски в previous_year_rating 0, что обозначает отсутствие оценки. Давать оценку от 1 до 5 будет некорректно, потому что сотрудник еще не оценивался. В education пропуски заменим на 'secondary', так как такие сотрудники, вероятно, имеют среднее образование, учитывая особенности образования в Индии.

```
# Заполняем пропуски в рейтинге за прошлый год нулями (0 = нет оценки)
df['previous_year_rating'].fillna(0, inplace=True)
```

```
# Заполняем пропуски в образовании: считаем, что это среднее образование
df['education'].fillna('secondary', inplace=True)
```

После этого проверяем, остались ли пропуски:

```
# Проверяем, остались ли пропуски в датасете
int(df.isna().sum().sum())

0
```

Преобразуем типы данных, так как оценка должна быть целочисленной (0-5).

```
# Преобразуем рейтинг из float в int
df['previous_year_rating'] = df['previous_year_rating'].astype(int)
```

Проверим датасет на дубликаты:

```
# Проверка дубликатов
int(df.duplicated().sum())

0
```

Дубликаты не обнаружены.

Удалим идентификатор сотрудника. Поле `employee_id` не несёт аналитической нагрузки, поэтому удалено, чтобы не мешать анализу.

```
# Удаляем идентификатор сотрудника
df.drop(columns='employee_id', inplace=True)
```

Контрольная проверка структуры данных:


```
# Контрольная проверка данных
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 23490 entries, 0 to 23489
Data columns (total 12 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   department                            23490 non-null  object
1   region                                23490 non-null  object
2   education                             23490 non-null  object
3   gender                                23490 non-null  object
4   recruitment_channel                   23490 non-null  object
5   trainings_count                       23490 non-null  int64
6   age                                   23490 non-null  int64
7   previous_year_rating                 23490 non-null  int64
8   service_years                        23490 non-null  int64
9   kpi_met_80                           23490 non-null  int64
10  awards_won                           23490 non-null  int64
11  avg_training_score                    23490 non-null  int64
dtypes: int64(7), object(5)
memory usage: 2.2+ MB
```

Теперь 12 признаков, все типы данных корректны: категориальные (object) и числовые (int64).

Визуализируем распределения признаков:

```
# Визуализация распределения
df.hist(edgecolor='black',
        linewidth=1,
        figsize=(15, 15))
plt.show()
```



- Распределение количества посещенных тренингов (`trainings_count`) резко скошено влево: подавляющее большинство сотрудников проходили 1-2 тренинга, которые вероятно являются обязательными для сотрудников.
- Распределение возраста (`age`) близко к нормальному, с пиком в диапазоне 30-35 лет.
- Наибольшее количество сотрудников имеют рейтинг 3-5, что говорит о положительных оценках большинства (`previous_year_rating`)
- Распределение стажа (`service_years`) скошено влево: большинство сотрудников работают до 10 лет, пик на уровне 3-5 лет. Небольшое количество выбросов у сотрудников со стажем более 20 лет.
- Около 60% сотрудников не достигли порога 80% KPI, а 40% выполнили KPI (`kpi_met_80`).
- Подавляющее большинство сотрудников не получали награды, только около 1-2% имеют награды (`awards_won`).
- У большинства сотрудников результаты обучения выше 50, средний балл около 60 (`avg_training_score`).

ЗАКЛЮЧЕНИЕ

В ходе выполнения лабораторной работы был проведен анализ и предобработка данных о сотрудниках компании. Данные были загружены, исследованы и очищены от пропусков и дубликатов. Названия столбцов и категориальные признаки были приведены к единому формату.

Рекомендации заказчику:

- В источнике данных отсутствует единый формат записи образования: рекомендуется ограничить ввод через выпадающий список.
- Поле КРІ стоит хранить не только в виде флага, но и в виде процента.