

Методические указания к выполнению проекта

«Интеллектуальный анализ набора данных»

Оглавление

1. Введение и постановка цели (ЛР1).....	1
2. Предварительный обзор данных (ЛР1)	1
3. Предобработка данных (ЛР1)	2
4. Исследовательский анализ данных (EDA) (ЛР2).....	2
5. Визуализация данных (ЛР3)	3
6. Прогнозирование и моделирование (ЛР4)	3
7. Формулировка выводов (ЛР1 – 4)	4

Цель проекта

Научиться проводить полный цикл анализа данных — от формулировки исследовательской цели до построения моделей и оформления итогового отчета. Работа должна показать ваше умение работать с реальными данными, обосновывать принимаемые решения и грамотно представлять результаты.

1. Введение и постановка цели (ЛР1)

Что делаем:

1. Внимательно изучить описание выбранного датасета (источник, тематика, структура, назначение).
2. Сформулировать четкую цель исследования. Цель должна быть измеримой (например: «выявить топ-3 факторов, влияющие на уровень заработной платы») и достижимой в рамках доступных данных.
3. Определить конкретные исследовательские задачи (например: «провести очистку данных», «построить модель прогнозирования»).
4. Составить список гипотез, которые можно проверить (например: «пол и возраст влияют на уровень дохода»). Каждая гипотеза должна быть проверяема средствами анализа данных.

2. Предварительный обзор данных (ЛР1)

Что делаем:

1. Изучить документацию к датасету. Ответить на вопросы: откуда данные, как собирались, какие есть ограничения.

2. Загрузить данные в среду анализа (Python + pandas).
3. Провести первичный обзор:
 - Определить количество строк и столбцов.
 - Изучить типы данных в каждом столбце.
 - Проверить наличие пропусков и дубликатов.
 - Получить базовые статистики (mean, median, min, max, std).

Инструменты:

- pandas.read_csv(), df.info(), df.describe(), df.head().
- Первичные визуализации: гистограммы и графики распределений (matplotlib) – берем самую простую диаграмму.

3. Предобработка данных (ЛР1)

Что делаем:

1. Обработка пропусков:

Определяем стратегию (удаление, заполнение средним/медианой, использование специальных меток). Обосновываем выбранный метод. Фиксируем все изменения.

2. Работа с дубликатами:

Находим повторяющиеся записи. Принимаем и обосновываем решение, стоит ли их удалять.

Инструменты:

- pandas: обработка пропусков (fillna(), dropna()).
- удаление дубликатов (drop_duplicates()), преобразования типов.

В конце раздела пишем о своих наблюдениях, отмечаем возможные проблемы, и что с ними нужно сделать заказчику (сборщику данных). Например, проверить функцию записи трудовых дней. Можно сразу выписать рекомендации, например, сделать выпадающий список в форму вместо свободного ввода.

4. Исследовательский анализ данных (EDA) (ЛР2)

Что делаем:

1. Изучаем распределения признаков:
 - Строим гистограммы.
 - Проверяем нормальность распределений, описываем распределения.

- Находим и комментируем оставшиеся выбросы.
- 2. Проводим корреляционный анализ:
 - Строим корреляционную матрицу.
 - Визуализируем с помощью heatmap.
- 3. Ищем закономерностей:
 - Проверяем наличие сезонных или временных паттернов (если набор данных позволяет).

Инструменты:

- matplotlib / seaborn: гистограммы, boxplot, scatter plot, heatmap
- pandas-profiling или ydata-profiling: автоматический отчёт по данным (опционально, если разберетесь)
- scipy.stats: проверки нормальности распределений, статистические тесты(опционально, если необходимо).

5. Визуализация данных (ЛР3)

Основные графики:

- Гистограммы
- Боксплоты
- Scatter plot
- Heatmap
- Boxen/violin plot при необходимости

Требования к оформлению:

- У каждого графика — заголовок.
- Оси подписаны.
- Легенды понятные, единицы измерения определены.
- Стиль и цвета должны быть единообразными во всем проекте.

Инструменты:

- **matplotlib / seaborn** — стандарт для графиков.
- **plotly / bokeh** — интерактивные визуализации (опционально).
- **Tableau / Power BI** (опционально) — дашборды для презентации результатов.

6. Прогнозирование и моделирование (ЛР4)

Что делаем:

1. Закодируйте категориальный признаки.

2. Выполните нормализацию\стандартизацию числовых признаков (объясните, что это и зачем).
3. Разделить данные на обучающую и тестовую выборки (train/test split).
4. Выбрать несколько моделей (2 и более) для сравнения:
 - Линейная регрессия
 - Деревья решений
 - Random Forest
 - Gradient Boosting
5. Оценить качество моделей:
 - Подобрать метрики (RMSE, MAE, Accuracy, F1 — зависит от задачи).
 - Провести кросс-валидацию.
 - Проанализировать ошибки и сделать выводы.

Инструменты:

- scikit-learn: LabelEncoder, OneHotEncoder — кодирование категориальных признаков, StandardScaler, MinMaxScaler — нормализация и стандартизация.
- scikit-learn: Линейные модели (LinearRegression, LogisticRegression), Деревья решений (DecisionTreeClassifier/Regressor), Случайный лес (RandomForest), Градиентный бустинг (GradientBoosting, XGBoost, LightGBM, CatBoost)
- statsmodels: подробный статистический анализ моделей (p-values, доверительные интервалы)
- scikit-learn.model_selection: train_test_split, cross_val_score, GridSearchCV.

7. Формулировка выводов (ЛР1 – 4)

Структура итоговых выводов:

1. Подтверждение или опровержение гипотез.
2. Описание ключевых находок.
3. Практические рекомендации заказчику.
4. Указание на ограничения исследования.
5. Идеи для дальнейшей работы.

Рекомендации по выводам:

Выводы должны быть логичными и следовать из анализа, а не повторять описание данных. Начинайте стоит с ответа на основные исследовательские вопросы: подтвердились ли выдвинутые гипотезы, какие закономерности обнаружены и как они соотносятся с поставленной целью.

Каждый вывод должен опираться на конкретные факты, статистики или визуализации, а не на субъективные суждения. Избегаем неопределённых

выражений вроде «похоже» или «кажется». Если найдены зависимости, необходимо указать их характер (например, линейная, нелинейная, сильная, слабая). Отмечаем ограничения исследования, такие как качество данных, возможные искажения, недостающие признаки. В заключительной части выводов пишем предложения для дальнейшего анализа или будущих исследований, например: использование дополнительных данных, применение других моделей или методов.

Удачные формулировки

1. Подтверждение гипотезы:

«Гипотеза о влиянии уровня образования на доход подтвердилась: в выборке наблюдается статистически значимая положительная корреляция ($\rho=0.62$, $p<0.01$).»

2. Описание закономерности:

«Распределение возрастов сотрудников имеет бимодальный характер с пиками в диапазонах 25–30 и 45–50 лет, что указывает на наличие двух основных возрастных групп в компании.»

3. Практическая значимость:

«Результаты кластеризации клиентов по расходам позволили выделить сегмент с высокой лояльностью, что может быть использовано для таргетированных маркетинговых кампаний.»

4. Указание на ограничения:

«Анализ ограничен отсутствием данных о стаже работы, что могло бы повысить точность модели прогнозирования.»

5. Рекомендации для будущих исследований:

«Для более точного прогноза имеет смысл расширить набор признаков, включив показатели региона проживания и семейного положения.»

Неудачные формулировки

1. «Образование влияет на доход, но мы не уверены точно.» или «Образование определенно влияет на доход.» — слишком неопределённо и голословно, ткнули пальцем в небо.
2. «Возраст распределён как-то странно.» — не конкретизировано, не указаны особенности распределения.
3. «Кластеризация получилась интересной.» — в чём именно интерес, и как это применимо. Кому-то это может быть вообще неинтересно. Убираем субъективные характеристики.
4. «Наши данные плохие.» — неконструктивно, нужно чётко указать, какие именно ограничения присутствуют.
5. «Надо собрать ещё какие-то данные, тогда сможем сказать точнее.» — слишком общее утверждение, без конкретики о том, какие данные могут быть полезны.
6. «В ходе проекта я научился анализировать данные.» - молодец :)

